

**UNIVERSIDAD DE SAN CARLOS DE GUATEMALA ESCUELA
DE ESTUDIO POSTGRADO
MAESTRÍA EN INGENIERÍA PARA LA INDUSTRIA CON
ESPECIALIDAD EN CIENCIAS DE LA COMPUTACIÓN**



CURSO: INTRODUCCIÓN A LA MINERÍA DE DATOS

TAREA 6

Repositorio: <https://github.com/jamesg19/DataMining/tree/main/Homework6>

James Osmin Gramajo Carcamo 999015976

Algoritmo Random Forest

Preparación de los datos

Se utilizó el archivo “base-de-datos-violencia-intrafamiliar-ano-2024_v3.xlsx”, del cual se extrajeron las siguientes variables:

- HEC_DEPTO (variable objetivo)
- AGR_EDAD
- AGR_ESCOLARIDAD
- AGR_TRABAJA
- AGR_SEXO

Posteriormente:

- Se transformó *HEC_DEPTO* a factor.
- Se eliminaron observaciones con valores faltantes (na.omit).
- Se aleatoriza el dataset para evitar sesgos.
- Se divide en 80% entrenamiento y 20% prueba.

Entrenamiento del modelo Random Forest

El modelo se entrenó con los parámetros:

- ntree = 100 (número de árboles)
- mtry = 4 (número de variables seleccionadas por división)
- Variables predictoras: edad, escolaridad, condición laboral y sexo.

El modelo entrenado queda almacenado como bosque.

Datos de testeo:

Se ingresó una persona de prueba:

Variable	Valor
AGR_EDAD	20
AGR_ESCOLARIDAD	52
AGR_TRABAJA	1
AGR_SEXO	1

Precision general:

```
[1] 0.2619503
```

Interpretacion:

Eso significa que sólo predice bien el 26.20% de los casos.

Salida en consola:

```
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 99
1 0.02 0 0.02 0.01 0 0.02 0 0 0.58 0 0.05 0 0 0 0 0 0 0 0.03 0.27 0 0
```

Interpretación de resultados:

- Hay un 58% de probabilidad de que el caso pertenezca al departamento 9 (Quetzaltenango).
- 27% de probabilidad de que sea 21 (Jalapa)
- 5% para 11 (Retalhuleu)

Gráfico de Arboles Vs Error

